Proyecto1

Juan Luis Solórzano (carnet: 201598) Micaela Yataz (carnet: 18960)

2025-01-20

1. (3 puntos) Haga una exploración rápida de sus datos, para eso haga un resumen de su conjunto de datos.

```
## Warning: NAs introduced by coercion
## Warning: NAs introduced by coercion
```

```
##        id              budget             genres            homePage
##  Min.   :     5   Min.   :        0   Length:3804        Length:3804
##  1st Qu.: 29807   1st Qu.:        0   Class :character   Class :character
##  Median :295644   Median :  3500000   Mode  :character   Mode  :character
##  Mean   :291505   Mean   : 24335422
##  3rd Qu.:489998   3rd Qu.: 30000000
##  Max.   :922162   Max.   :380000000
##
##  productionCompany  productionCompanyCountry productionCountry
##  Length:3804        Length:3804              Length:3804
##  Class :character   Class :character         Class :character
##  Mode  :character   Mode  :character         Mode  :character
##
##
##
##
##     revenue             runtime        video           director
##  Min.   :0.000e+00   Min.   :  0.0   Mode :logical   Length:3804
##  1st Qu.:0.000e+00   1st Qu.: 91.0   FALSE:3781      Class :character
##  Median :3.982e+06   Median :102.0   TRUE :23        Mode  :character
##  Mean   :7.859e+07   Mean   :103.3
##  3rd Qu.:7.009e+07   3rd Qu.:116.0
##  Max.   :2.847e+09   Max.   :400.0
##
##     actors          actorsPopularity   actorsCharacter    originalTitle
##  Length:3804        Length:3804        Length:3804        Length:3804
##  Class :character   Class :character   Class :character   Class :character
##  Mode  :character   Mode  :character   Mode  :character   Mode  :character
##
##
##
##
##     title           originalLanguage     popularity        releaseDate
##  Length:3804        Length:3804        Min.   :    6.781   Length:3804
##  Class :character   Class :character   1st Qu.:   15.774   Class :character
##  Mode  :character   Mode  :character   Median :   24.951   Mode  :character
##                                        Mean   :   68.185
```

```
##                                      3rd Qu.:   46.337
##                                      Max.   :11474.647
##
##     voteAvg         voteCount        genresAmount    productionCoAmount
##  Min.   : 1.300   Min.   :    1.0   Min.   : 0.000   Min.   : 0.000
##  1st Qu.: 6.100   1st Qu.:  173.8   1st Qu.: 2.000   1st Qu.: 2.000
##  Median : 6.600   Median :  680.5   Median : 3.000   Median : 3.000
##  Mean   : 6.616   Mean   : 1871.4   Mean   : 2.664   Mean   : 3.493
##  3rd Qu.: 7.200   3rd Qu.: 2051.0   3rd Qu.: 3.000   3rd Qu.: 5.000
##  Max.   :10.000   Max.   :30788.0   Max.   :16.000   Max.   :25.000
##
##  productionCountriesAmount  actorsAmount      castWomenAmount  castMenAmount
##  Min.   : 0.000            Min.   :     0.0   Min.   :     0   Min.   :     0
##  1st Qu.: 1.000            1st Qu.:    14.0   1st Qu.:     4   1st Qu.:     7
##  Median : 1.000            Median :    24.0   Median :     7   Median :    12
##  Mean   : 1.708            Mean   :   685.7   Mean   :  3067   Mean   : 11369
##  3rd Qu.: 2.000            3rd Qu.:    41.0   3rd Qu.:    11   3rd Qu.:    21
##  Max.   :57.000            Max.   :784594.0   Max.   :922162   Max.   :899405
##                                               NA's   :5        NA's   :24
```

2. (5 puntos) Diga el tipo de cada una de las variables (cualitativa ordinal o nominal, cuantitativa continua, cuantitativa discreta)

```
##                                        tipo
## id                            cualitatva nominal
## budget                      cuantitativa discreta
## genres                        cualitatva nominal
## homePage                      cualitatva nominal
## productionCompany             cualitatva nominal
## productionCompanyCountry      cualitatva nominal
## productionCountry             cualitatva nominal
## revenue                     cuantitativa discreta
## runtime                     cuantitativa discreta
## video                         cualitatva nominal
## director                      cualitatva nominal
## actors                        cualitatva nominal
## actorsPopularity            cuantitativa continua
## actorsCharacter               cualitatva nominal
## originalTitle                 cualitatva nominal
## title                         cualitatva nominal
## originalLanguage              cualitatva nominal
## popularity                  cuantitativa continua
## releaseDate                   cualitativa ordinal
## voteAvg                     cuantitativa continua
## voteCount                   cuantitativa discreta
## genresAmount                cuantitativa discreta
## productionCoAmount          cuantitativa discreta
## productionCountriesAmount cuantitativa discreta
## actorsAmount                cuantitativa discreta
## castWomenAmount             cuantitativa discreta
## castMenAmount               cuantitativa discreta
```

3. (6 puntos) Investigue si las variables cuantitativas siguen una distribución normal y haga una tabla de frecuencias de las variables cualitativas. Explique todos los resultados.

```
##                                                 Variable      P_value
## voteAvg                                          voteAvg 1.494879e-16
## voteCount                                      voteCount 3.700000e-24
## genresAmount                                genresAmount 3.700000e-24
## productionCoAmount                    productionCoAmount 3.700000e-24
## productionCountriesAmount productionCountriesAmount 3.700000e-24
## actorsAmount                                actorsAmount 3.700000e-24
## castWomenAmount                          castWomenAmount 3.700000e-24
## castMenAmount                              castMenAmount 3.700000e-24
```

Como se puede ver en la tabla de resumen de la prueba de Anderson-Darlin como el $p - valor < 0.01$ para cada variable se puede concluir que ninguna variable sigue una distribucion normal de estos datos.

```
## Warning: `aes_string()` was deprecated in ggplot2 3.0.0.
## i Please use tidy evaluation idioms with `aes()`.
## i See also `vignette("ggplot2-in-packages")` for more information.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

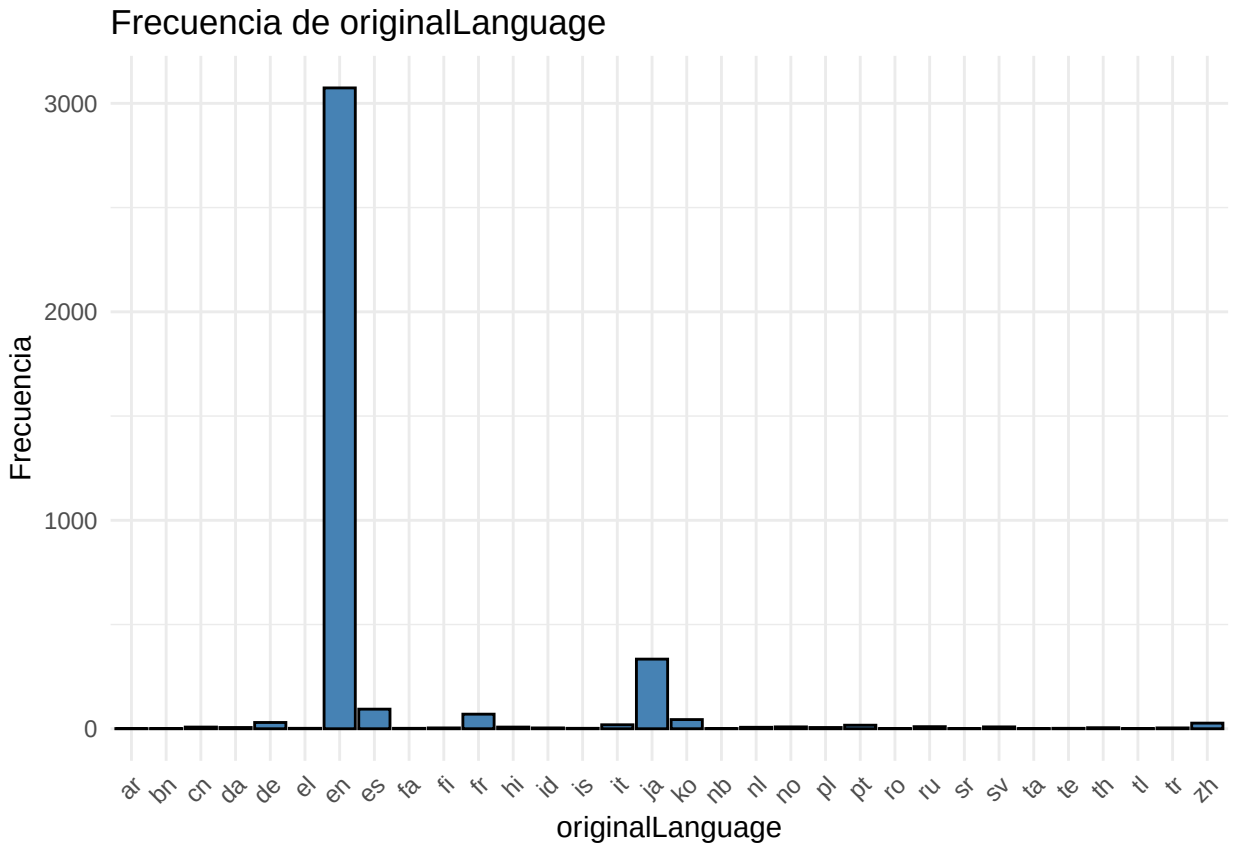

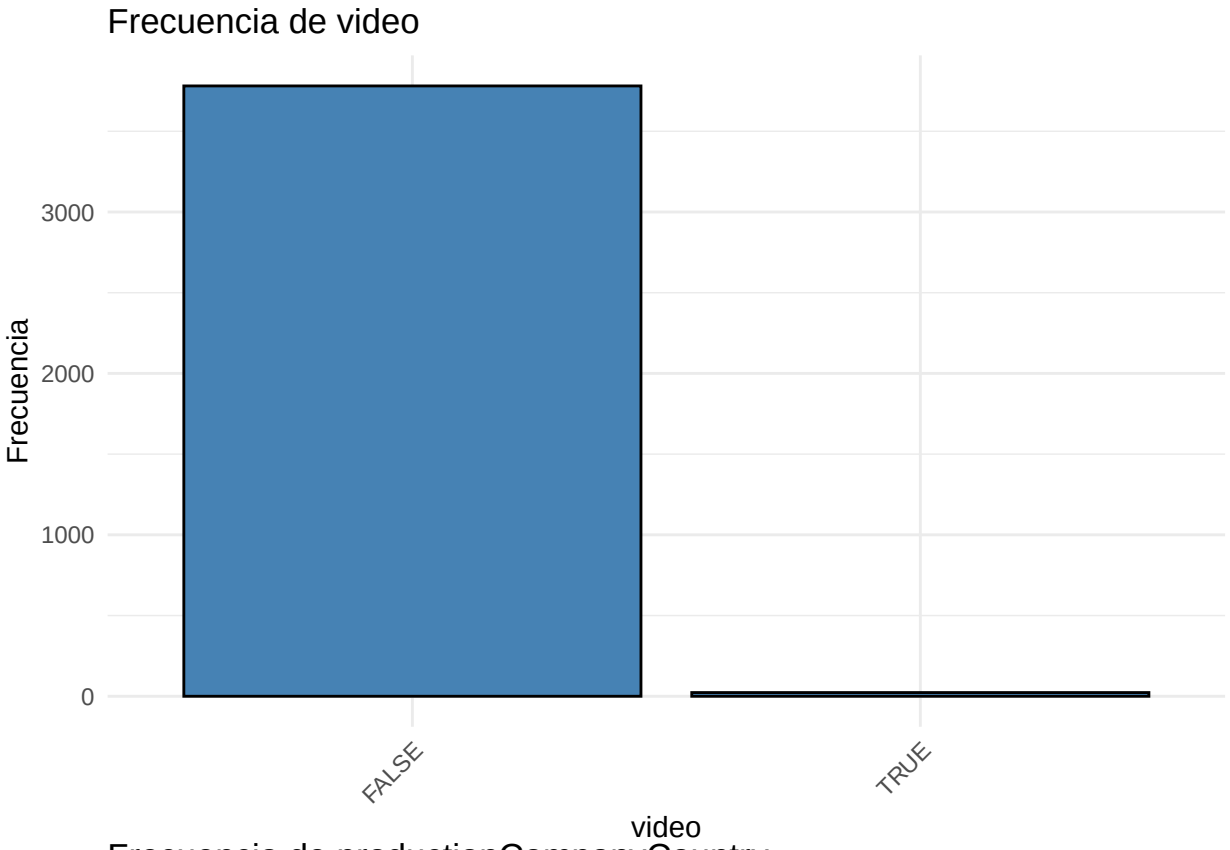

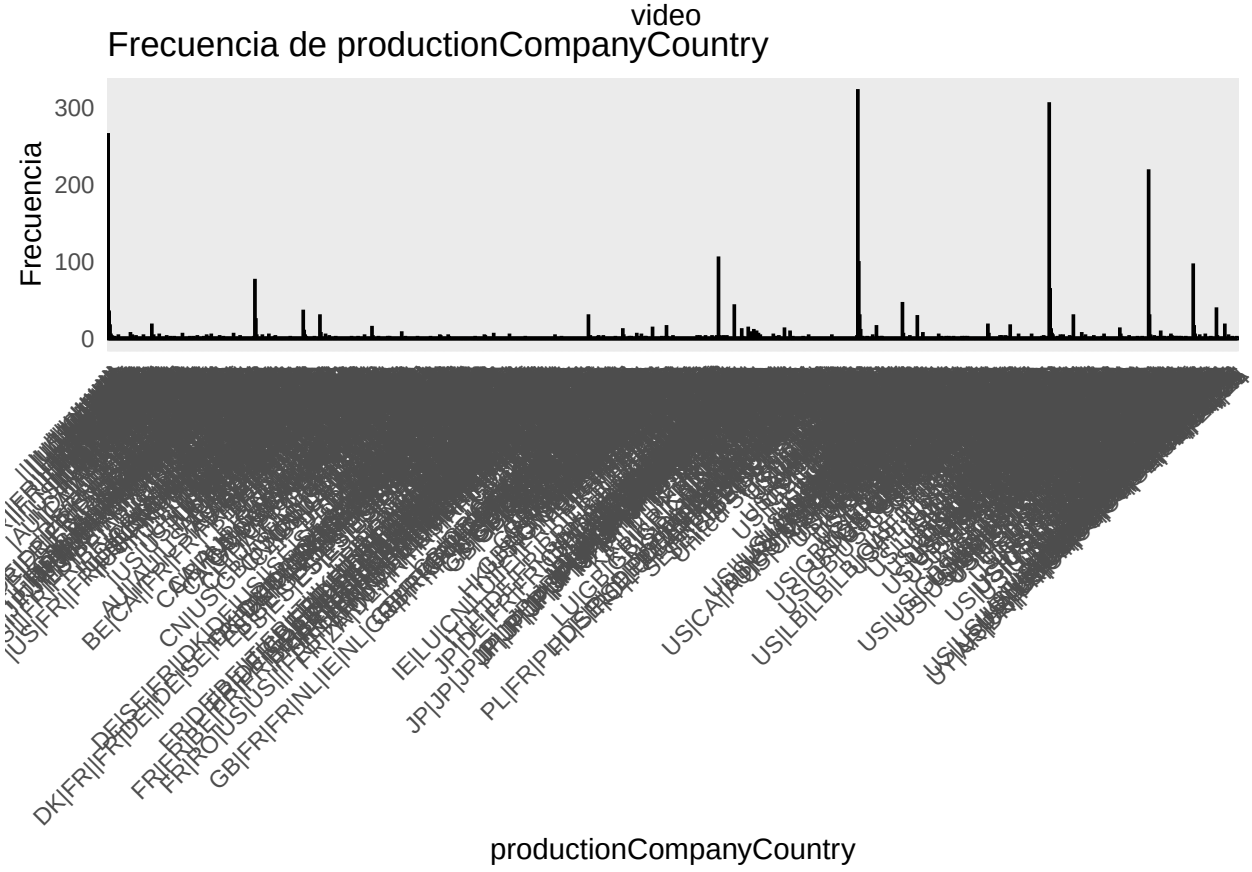

Las variables cualitativas cullas tablas no se muestran se debe a que son nombres de actores o cualquier otra

que tiene muchos posibles valores, al punto de ser únicas para cada película. Dicho eso podemos notar que el idioma original mas frecuente en estos datos es el ingles, seguido muy de lejos por el japones y el francés.

4. Responda las siguientes preguntas:

4.1. (3 puntos) ¿Cuáles son las 10 películas que contaron con más presupuesto?

Las 10 peliculas con mayor presupuesto fueron:

```
##                                     originalTitle    budget
## 717   Pirates of the Caribbean: On Stranger Tides 380000000
## 4711                       Avengers: Age of Ultron 365000000
## 5953                             Avengers: Endgame 356000000
## 164      Pirates of the Caribbean: At World's End 300000000
## 5954                         Avengers: Infinity War 300000000
## 608                                Superman Returns 270000000
## 7135                                  The Lion King 260000000
## 281                                    Spider-Man 3 258000000
## 412         Harry Potter and the Half-Blood Prince 250000000
## 2509 Harry Potter and the Deathly Hallows: Part 1 250000000
```

4.2. (3 puntos) ¿Cuáles son las 10 películas que más ingresos tuvieron?

Las 10 películas con mayores ingresos fueron:

```
## data frame with 0 columns and 10 rows
```

4.3. (3 puntos) ¿Cuál es la película que más votos tuvo?

La película que más votos tuvo fue Inception.

4.4. (3 puntos) ¿Cuál es la peor película de acuerdo a los votos de todos los usuarios?

La peor película fue STAR DRIVER <U+9583><U+4EAE><U+7684><U+5854><U+514B><U+7279> THE MOVIE.

4.5. (8 puntos) ¿Cuántas películas se hicieron en cada año? ¿En qué año se hicieron más películas? Haga un gráfico de barras.

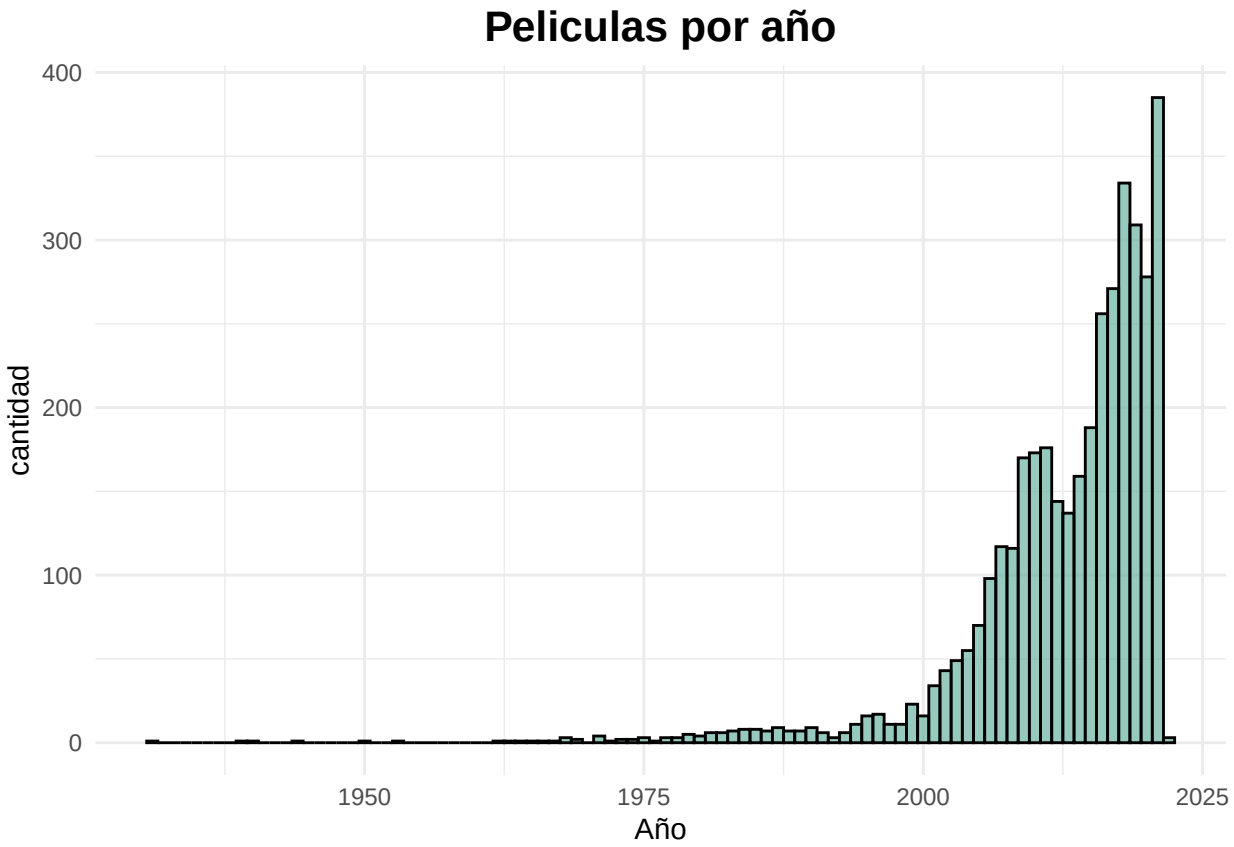

El año que se rodaron más películas fue el 2021

4.6. (9 puntos) ¿Cuál es el género principal de las 20 películas más recientes? ¿Cuál es el género principal que predomina en el conjunto de datos? Represéntelo usando un gráfico. ¿A qué género principal pertenecen las películas más largas?

4.7. (8 puntos) ¿Las películas de qué género principal obtuvieron mayores ganancias?

Vamos a tomar a las películas por encima del percentil 97 P_{97} como las que obtuvieron mayores ganancias\

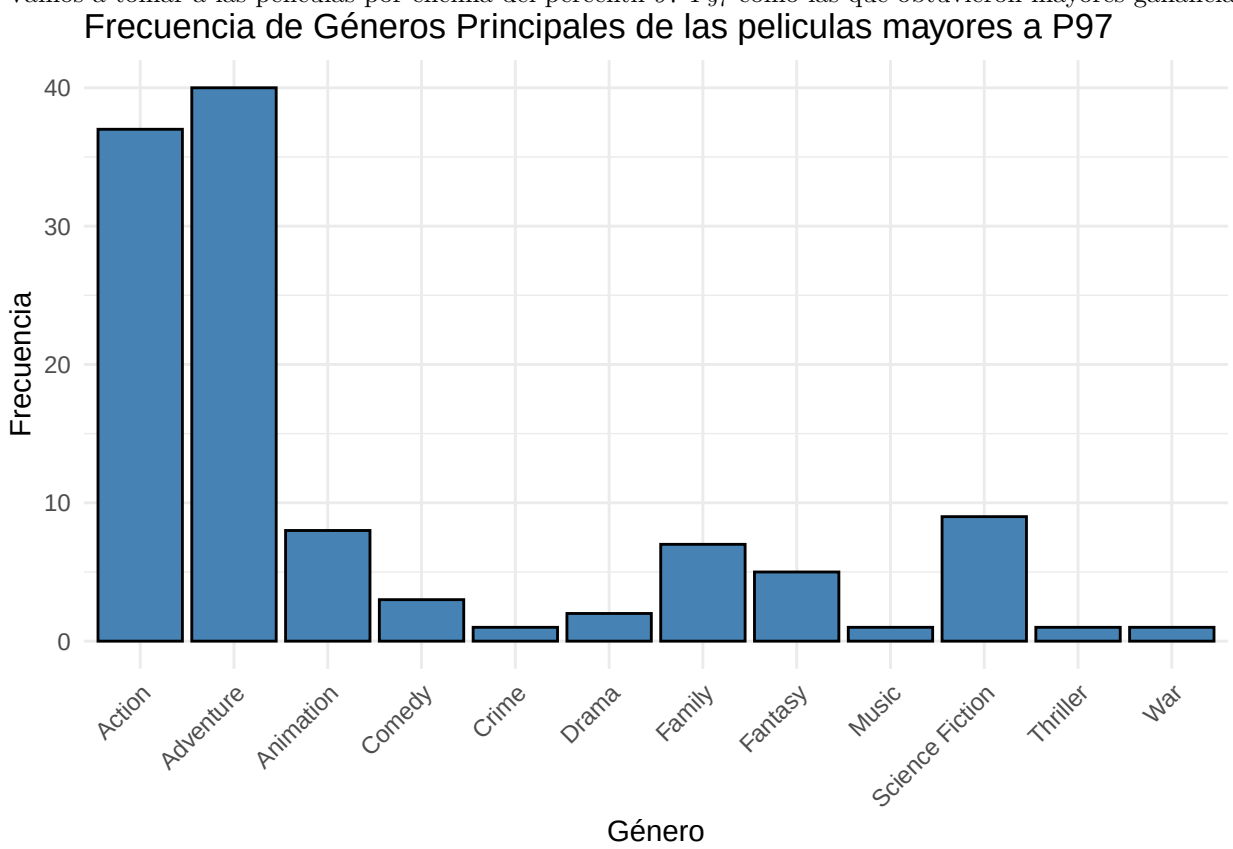

Como se puede apreciar en la gráfica de frecuencias, el genero principal de las peliculas con mayor ganancia es aventura y acción.

4.8. (3 puntos) ¿La cantidad de actores influye en los ingresos de las películas? ¿Se han hecho películas con más actores en los últimos años?

```
df <- pelis[,c("actorsAmount","revenue")]
df <- df %>% na.omit()
df <- as.data.frame(scale(df))

# Verificar estructura
str(df)
```

```
## 'data.frame':    3804 obs. of  2 variables:
##  $ actorsAmount: num  -0.0335 -0.0301 -0.032 -0.0343 -0.0323 ...
##  $ revenue     : num  14.84 14.58 10.55 8.52 8.33 ...
```

```
# Gráfica de pares con `ggpairs()`
ggpairs(df)
```

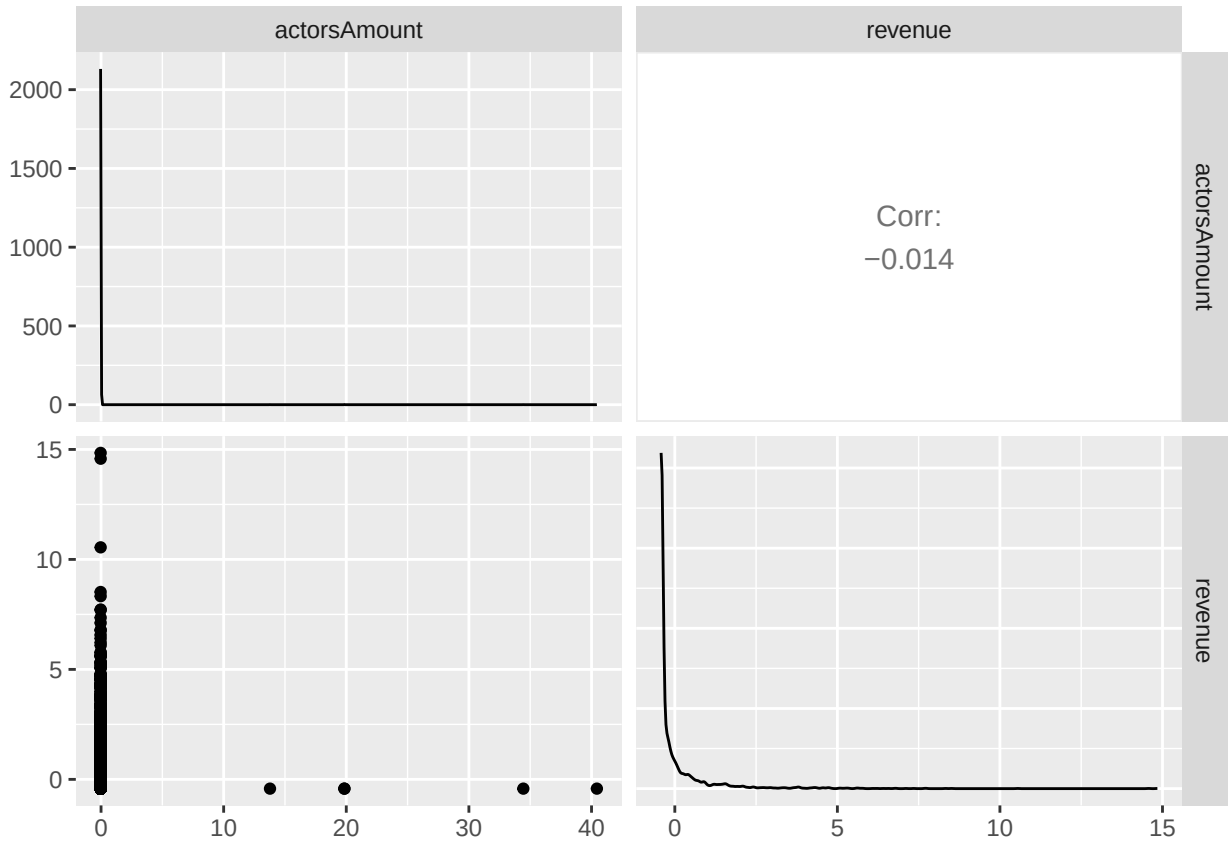

4.9. (3 puntos) ¿Es posible que la cantidad de hombres y mujeres en el reparto influya en la popularidad y los ingresos de las películas?

```
## 'data.frame':    3780 obs. of  4 variables:
##  $ revenue        : num  14.8 14.54 10.52 8.49 8.3 ...
##  $ castWomenAmount: num  0.13 2.88 1.867 -0.304 0.709 ...
##  $ castMenAmount  : num  -0.137 -0.136 -0.136 -0.137 -0.136 ...
##  $ popularity     : num  1.498 1.08 1.773 0.322 25.575 ...
```

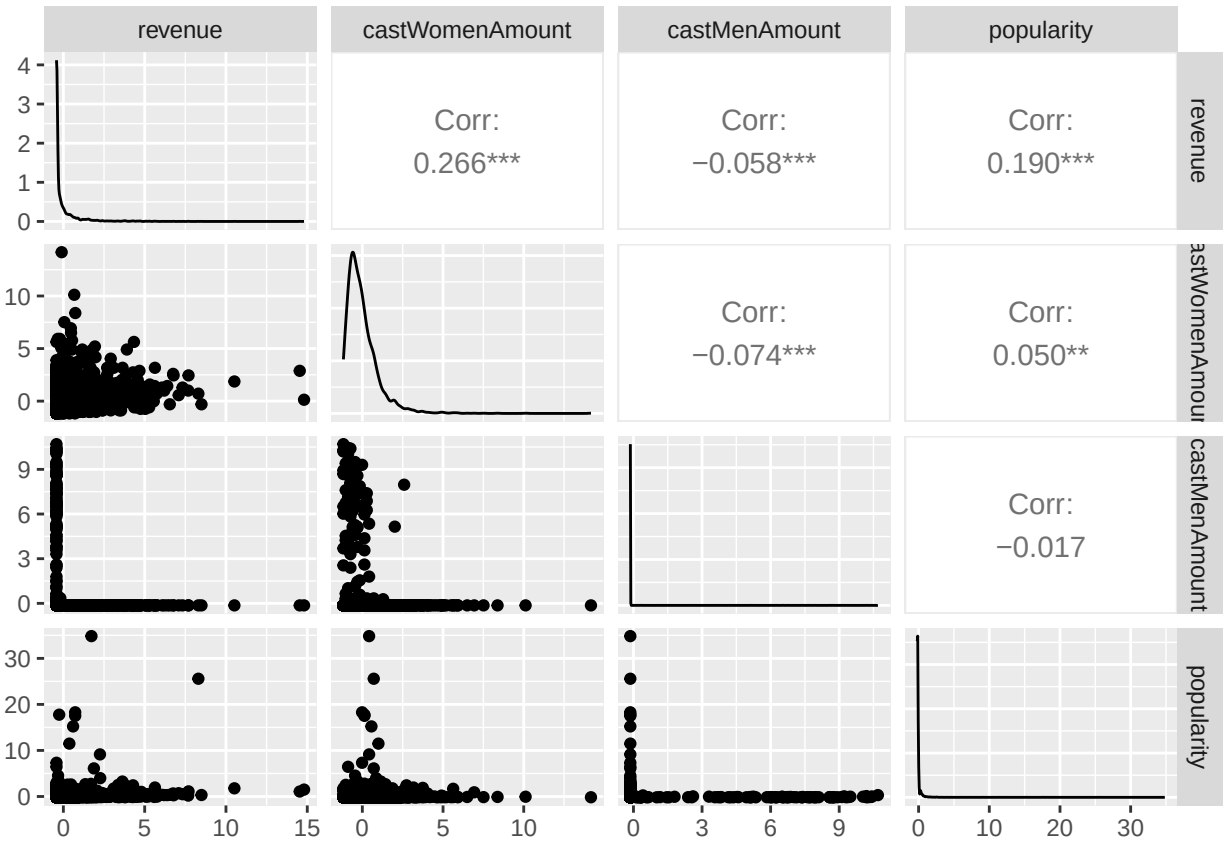

Como el coeficiente d

4.10. (8 puntos) ¿Quiénes son los directores que hicieron las 20 películas mejor calificadas?

```
pelis_ord <- pelis[order(-pelis$popularity),]


head(pelis_ord$director,20)
```

```
##  [1] "Chlo\xe9 Zhao"           "Jon Watts"
##  [3] "Garth Jennings"          "Johannes Roberts"
##  [5] "Byron Howard|Jared Bush" "Jason Reitman"
##  [7] "Lana Wachowski"          "Andy Serkis"
##  [9] "Mattson Tomlin"          "Rawson Marshall Thurber"
## [11] "Destin Daniel Cretton"   "Scott Cooper"
## [13] "Haruo Sotozaki"          "Ridley Scott"
## [15] "Marc Webb"               "Takayuki Hamana"
## [17] "Cary Joji Fukunaga"      "Denis Villeneuve"
## [19] "Shawn Levy"              "James Gunn"
```

4.11. (8 puntos) ¿Cómo se correlacionan los presupuestos con los ingresos? ¿Los altos presupuestos significan altos ingresos? Haga los gráficos que necesite, histograma, diagrama de dispersión.

```
## 'data.frame':    3804 obs. of  2 variables:
##  $ revenue: num  14.84 14.58 10.55 8.52 8.33 ...
##  $ budget : num  4.87 7.6 6.31 5.4 4.02 ...
```

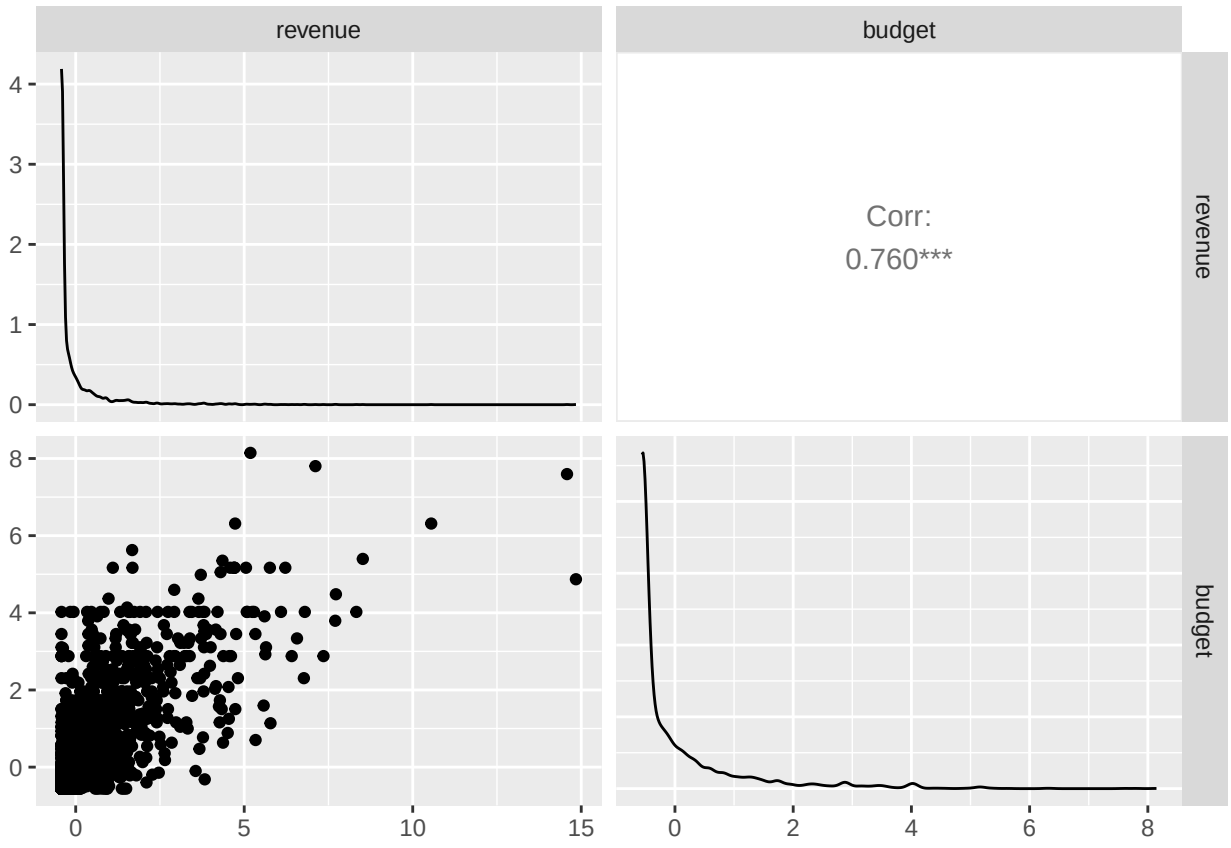
revenue
budget
Corr:
0.760***
revenue
budget
0
1
2
3
4
0
2
4
6
8
0
5
10
15
0
2
4
6
8

4.12. (5 puntos) ¿Se asocian ciertos meses de lanzamiento con mejores ingresos?

4.13. (6 puntos) ¿En qué meses se han visto los lanzamientos con mejores ingresos? ¿Cuántas películas, en promedio, se han lanzado por mes?

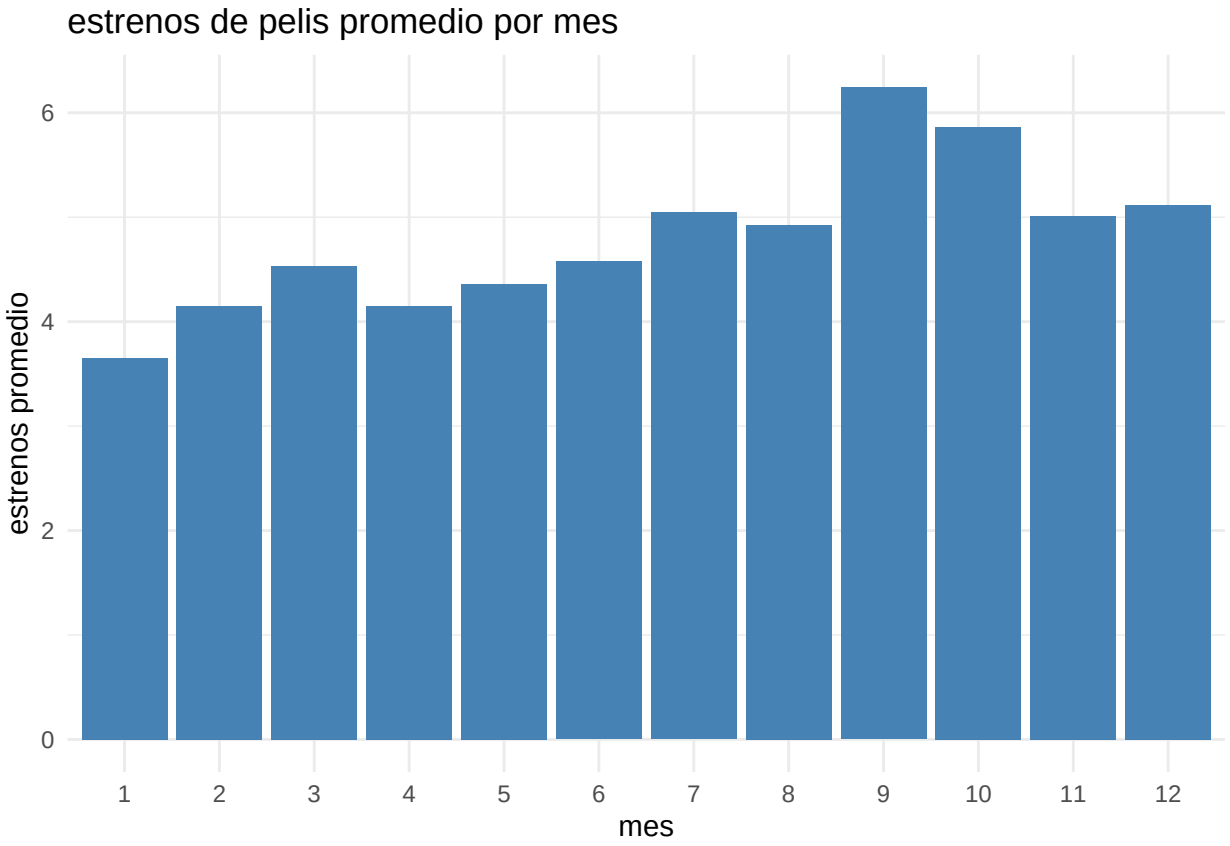

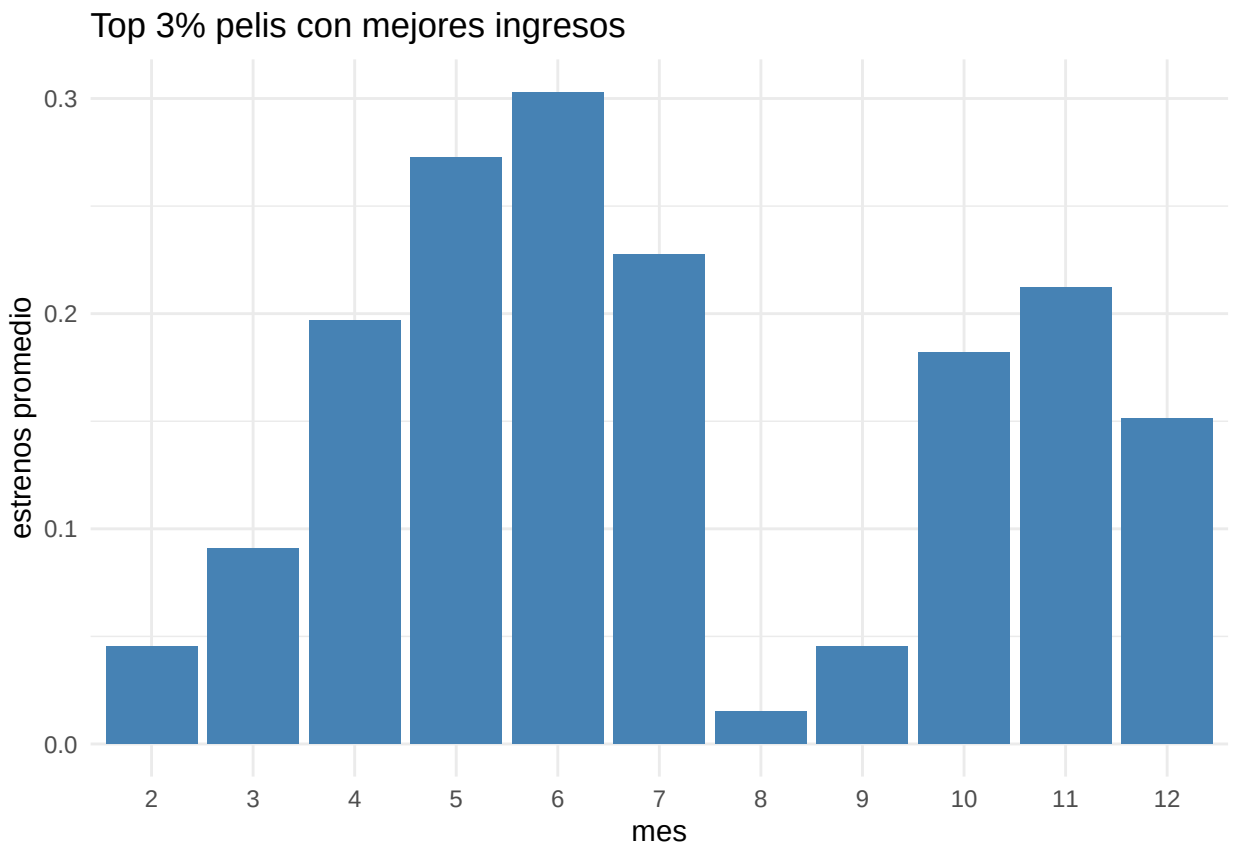
Top 3% pelis con mejores ingresos
estrenos promedio
0.0
0.1
0.2
0.3
2
3
4
5
6
7
8
9
10
11
12
mes

4.14. (7 puntos) ¿Cómo se correlacionan las calificaciones con el éxito comercial?

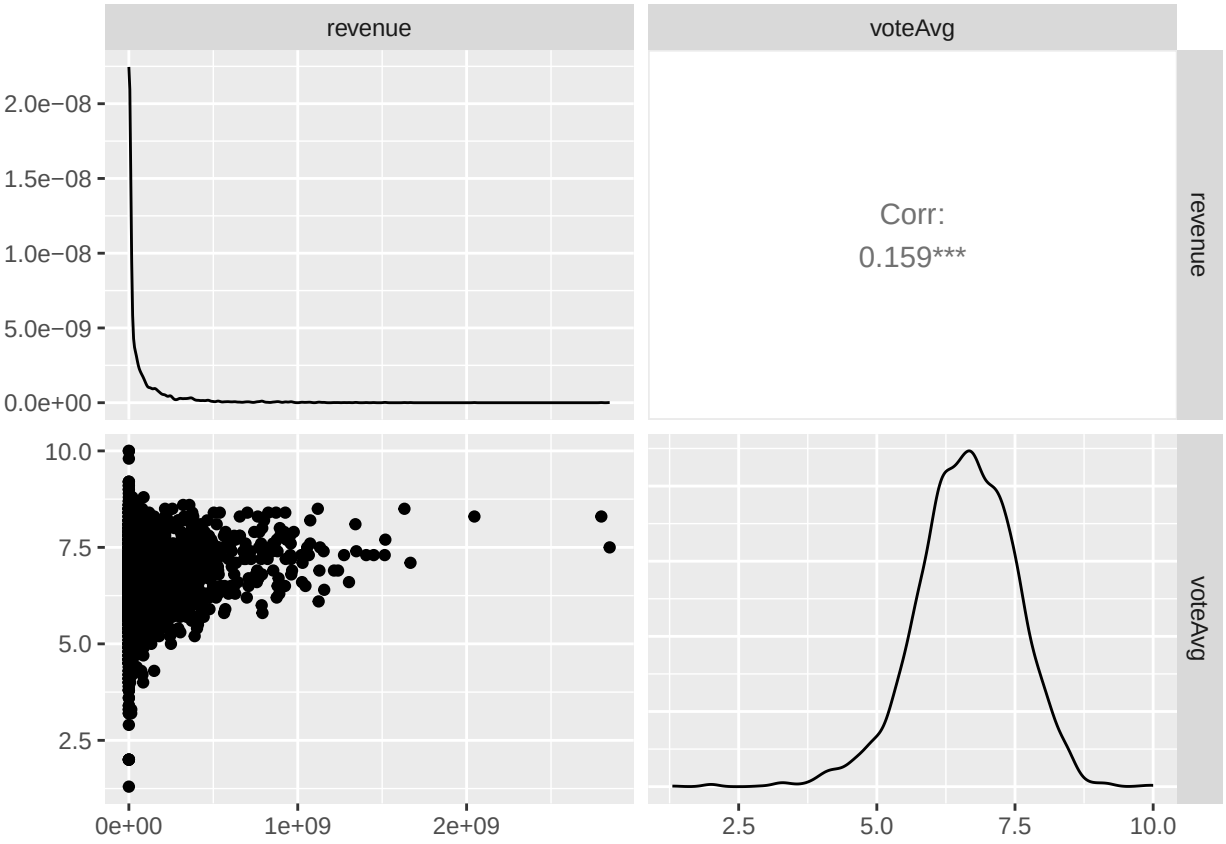

4.15. (5 puntos) ¿Qué estrategias de marketing, como videos promocionales o páginas oficiales, generan mejores resultados?

Mica esto no se me ocurre que hacer

4.16. (4 puntos) ¿La popularidad del elenco está directamente correlacionada con el éxito de taquilla?

```
## Warning: There were 12 warnings in `mutate()`.
## The first warning was:
## i In argument: `avgPopularity = sapply(...)`.
## Caused by warning in `strsplit()`:
## ! unable to translate 'Self - President, Marvel Studios (archive footage)|Self - Director (archive f
## i Run `dplyr::last_dplyr_warnings()` to see the 11 remaining warnings.

## Warning: Removed 33 rows containing non-finite outside the scale range
## (`stat_density()`).

## Warning in ggally_statistic(data = data, mapping = mapping, na.rm = na.rm, :
## Removed 33 rows containing missing values

## Warning: Removed 33 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

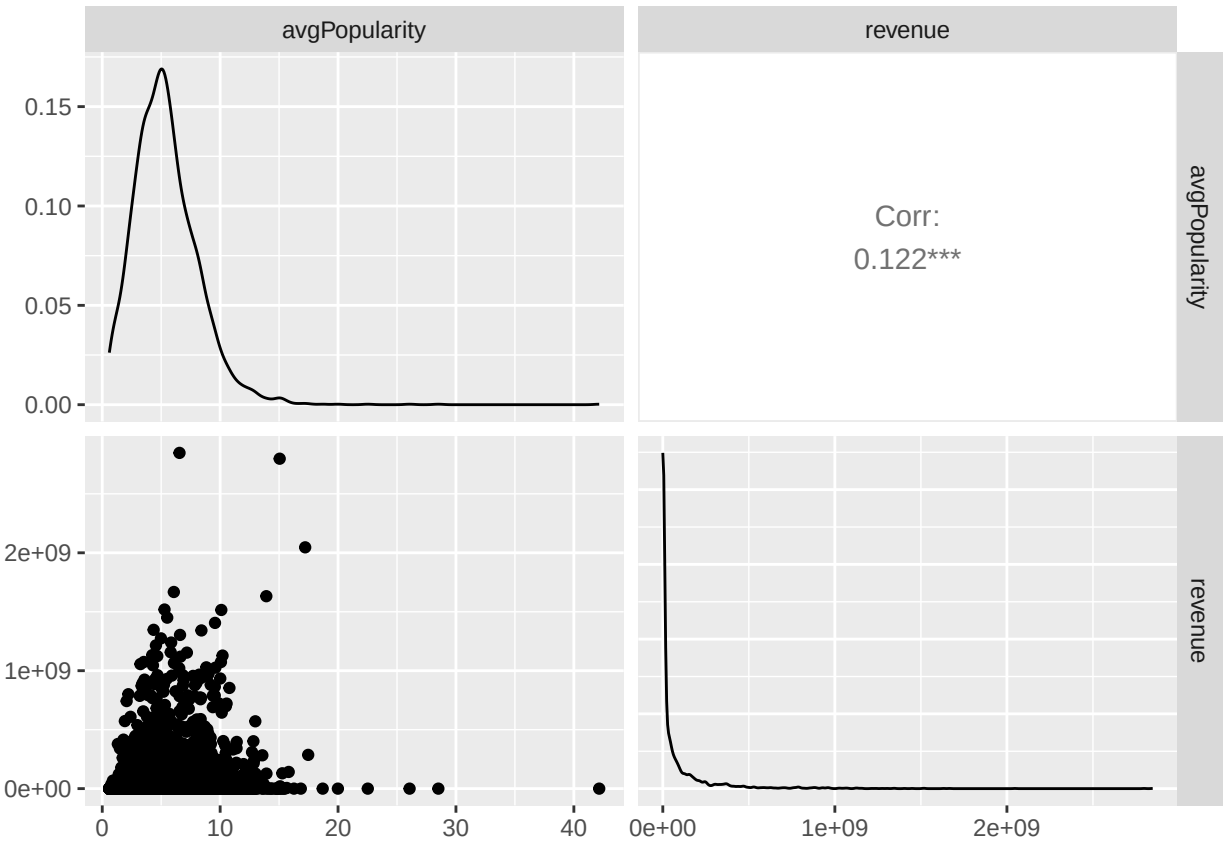

5. (¡10 puntos extras!) Genere usted otras seis preguntas que le parezcan interesantes porque le permitan realizar otras exploraciones y respóndalas. No puede repetir ninguna de las instrucciones anteriores.